

Anti-seche — Extraction de DNN au-dela de ReLU

Concepts clés pour maîtriser le thème · Tidiane · 2026

OBJECTIF EN UNE PHRASE

Voler les **paramètres** d'un réseau en l'interrogeant comme une **boîte noire**, et savoir s'en **defendre** — surtout quand l'activation n'est pas ReLU et quand l'attaquant ne voit que **l'étiquette finale (hard-label)**.

1 · CE QUE VOIT L'ATTAQUANT

Setting	Renvoie	Diff.	Realisme
Raw-output	scores [2.7,-0.4,1.1]	facile	moyen
Softmax	probabilités	facile	moyen
Hard-label	SEULE la classe (argmax)	DUR	ELEVE

Hard-label = cadre réaliste et difficile = le cœur de la thèse.

2 · ANATOMIE : NEURONE = HYPERPLAN

$z = w \cdot x + b$ puis $a = \sigma(z)$

$w \cdot x + b = 0$ définit un **hyperplan**. Chaque neurone = un hyperplan ; les attaques cherchent à les localiser.

La **couche de sortie n'a pas d'activation** -> elle résiste (article fondateur).

3 · ACTIVATIONS : DEUX FAMILLES

Sans non-linéarité, empiler des couches = 1 fonction linéaire (inutile). σ casse la linéarité ; sa **forme** décide de la difficulté d'attaque.

Famille	Exemples	Coude	Attaque
A · par morceaux	ReLU, Leaky, PReLU	OUI	facile
B · lisse	sigmoïde, GELU, SiLU	NON	casse

A : réseau AFFINE PAR MORCEAUX. B : courbe partout -> outils classiques KO.

4 · OU FUITE L'INFORMATION

Point critique (raw-output) : entrée ou un neurone = 0. Le ReLU bascule -> la **pente change brutalement** ; le saut révèle les poids.

Point de transition (hard-label) : entrée ou la **classe change** (frontière). Trouve par **recherche binaire** sur un **segment** $x_0+t \cdot d$.

5 · EXTRAIRE UNE COUCHE : 3 ETAPES

1. Signature — direction des poids (à un facteur près), via points critiques/transition.

2. Signe — signe du facteur. Exponentiel (Carlini 2020) -> polynomial (Canales-M. 2024).

3. Peeling — retirer la couche extraite, passer à la suivante.

But : EQUIVALENCE FONCTIONNELLE (même fonction, à symétries près).

6 · AU-DELA DE ReLU : CE QUI CHANGE

Famille A non-ReLU (PReLU, ELU) : coude présent mais $\neq 0$; estimer α ; fuite des **deux cotes** -> **signe plus facile**.

Famille B lisse (GELU, sigmoïde) : aucun coude. Parade raw-output = dérivées d'ordre supérieur — mais elles exigent la sortie continue...

... **absente en hard-label -> PERSONNE ne sait extraire un réseau lisse en hard-label**.

Piste : remplacer la courbure de la sortie par la **courbure de la frontière**.

7 · SE DEFENDRE (Train to Defend, 2025)

L'attaque marche mieux si les neurones d'une couche sont **distincts**. Défense : entraîner pour les rendre **similaires** -> l'attaque ne peut plus les séparer.

Coût < 1% de précision, zéro surcoût. Mon TP7 : 5/5 -> 3/5 neurones séparés.

1 seule défense publiée -> grosse opportunité hors ReLU.

8 · MINI-LEXIQUE

Terme	Définition express
Oracle	interroger sans voir l'intérieur
Logits	sortie brute (scores)
Hard-label	seulement la classe (argmax)
Signature	poids à un facteur près
Signe	signe de ce facteur
Peeling	extraire puis retirer une couche
Contractif	nb de neurones qui décroît