

MODULE 3

Attaques d'Extraction
de DNN

Doctorant	Tidiane DIALLO
Directeur	Pr. Abdoul Aziz Ciss — EPT
Période	Semaines 5-8 Mai-Juin 2026
Niveau	Intermédiaire → Avancé
Durée estimée	10-12 heures

Chapitre 1 — Contexte et Menace

Les DNN modernes sont déployés via des APIs (Machine Learning as a Service — MLaaS). Ces modèles représentent un investissement considérable. Une attaque d'extraction permet de reconstruire un modèle en l'interrogeant comme une boîte noire.

Acteur	Description	Exemple
Victime	Entreprise ayant entraîné un DNN coûteux	OpenAI, Google, Meta
Attaquant	Veut voler le modèle sans payer	Concurrent, hacker
Moyen	API publique du modèle	ChatGPT API, Google AI
Objectif	Reconstruire le modèle avec peu de requêtes	$f_{\square} \approx f$ avec coût minimal

Chapitre 2 — Taxonomie des Attaques

2.1 Selon le type de sortie observable

Type	Description	Exemple de réponse API	Difficulté
Soft-label	API retourne les probabilités	[0.85, 0.10, 0.05]	Facile
Hard-label	API retourne seulement la classe	"chat"	Difficile
Score	API retourne un score continu	0.923	Moyen

2.2 Selon l'objectif de l'attaquant

Objectif	Description	Résultat attendu
----------	-------------	------------------

Extraction exacte	Copier les poids exacts W, b	$f_{\text{ex}}(x) = f(x)$ pour tout x
Extraction fonctionnelle	Imiter le comportement	$f_{\text{ex}}(x) \approx f(x)$ sur distribution
Extraction de propriétés	Voler architecture/hyperparams	Connaître nb couches, activations

Chapitre 3 — Carlini et al. CRYPTO 2020 (Article fondateur)

Référence complète
Carlini, N., Jagielski, M., & Mironov, I. (2020). "Cryptanalytic Extraction of Neural Network Models." Advances in Cryptology — CRYPTO 2020. ArXiv: 1910.00866

Résultat principal
Pour un réseau ReLU à L couches et n neurones par couche, il est possible de reconstruire tous les paramètres (W, b) de manière exacte en temps polynomial $O(\text{poly}(n, L))$ en utilisant les différentielles du réseau.

Intuition de la méthode (version simplifiée)

Étape	Opération	Résultat
1. Choisir direction	Choisir vecteur d'entrée x et direction d	—
2. Interpoler	Calculer $f(x + t \cdot d)$ pour $t \in [-\epsilon, \epsilon]$	Courbe linéaire par morceaux
3. Trouver kink	Détecter le point de non-différentiabilité	Position d'un neurone ReLU
4. Extraire poids	Calculer W et b à partir du kink	Paramètres d'un neurone
5. Répéter	Pour chaque neurone, chaque couche	Réseau complet extrait

Pourquoi cela marche pour ReLU mais pas pour GELU
ReLU crée une courbe linéaire par morceaux: $f(x+td)$ est linéaire sur chaque segment, avec des kinks aux frontières des neurones. Ces kinks sont détectables avec précision. GELU est une courbe LISSE (infiniment dérivable): pas de kinks, pas de morceaux linéaires. La méthode de Carlini ne peut pas s'appliquer directement. C'est le verrou central de ta thèse.

Chapitre 4 — Articles Essentiels à Lire

Priorité	Article	Venue	Pourquoi le lire
★★★	Carlini et al. (2020): Cryptanalytic Extraction	CRYPTO 2020	FONDATEUR — Base de ta thèse
★★★	Canales-Martínez et al. (2024): Polynomial Time Extraction	EUROCRYPT 2024	SUITE DIRECTE — Amélioration majeure
★★★	Carlini et al. (2025): Hard-Label Extraction	EUROCRYPT 2025	ÉTAT DE L'ART — Hard-label setting
★★	Jagielski et al. (2020): High Accuracy Model Stealing	IEEE S&P; 2020	Vue d'ensemble model stealing
★★	Tramèr et al. (2016): Stealing Machine Learning Models	USENIX 2016	PREMIER article sur model stealing
★	Papernot et al. (2017): Practical Black-Box Attacks	AsiaCCS 2017	Attaques adversariales + extraction