

Proposition de thèse de Tidiane DIALLO

Projet de thèse de : Tidiane DIALLO

Intitulé du projet : Attaques d'extraction et défenses pour les réseaux de neurones profonds au-delà de ReLU

Mots-clés : Deep Learning, réseaux de neurones, fonctions d'activation, ReLU, sécurité des modèles, cryptographie, attaques d'extraction, hard-label, défenses, robustesse.

École doctorale : L'Ecole Doctorale Polytechnique Thiès (EDPT)

Direction de la thèse: Abdoul Aziz Ciss, Maître de conférences, EPT, aaciss@ept.edu.sn

Période : 2025 – 2028

Laboratoire d'accueil : Le doctorant sera accueilli à mi-temps au Laboratoire mixte de recherche (CRISIN'2D), au sein de l'équipe de recherche LTISI

1. Résumé

Cette proposition de thèse s'inscrit dans le contexte de la sécurité des modèles de Deep Learning. Les réseaux de neurones profonds (DNN) sont aujourd'hui massivement déployés via des API dans des domaines comme la vision, le langage ou l'aide à la décision. Ils représentent un investissement important en données, en calcul et en expertise, et constituent donc des actifs stratégiques à protéger.

Parallèlement, des travaux récents en cryptographie et en sécurité des systèmes d'IA ont montré que des attaques d'« extraction de modèles » permettent, dans certains cas, de reconstruire les paramètres internes d'un réseau de neurones en l'interrogeant simplement comme une boîte noire. Ces attaques existent déjà pour des réseaux à activation ReLU, y compris dans un cadre réaliste dit hard-label où l'attaquant ne voit que la classe prédite et non les sorties brutes.

Le projet de thèse proposé vise à prolonger ces travaux dans deux directions :

- (i) généraliser les attaques d'extraction à des modèles utilisant d'autres fonctions d'activation largement employées en pratique, telles que la sigmoïde, tanh, ainsi que des activations modernes comme GELU ou SiLU/Swish, et à des architectures plus proches des systèmes actuels (par exemple des réseaux convolutionnels) ;
- (ii) concevoir et analyser des mécanismes de défense permettant de rendre l'extraction beaucoup plus difficile ou coûteuse, tout en préservant la performance des modèles.

L'objectif de la thèse sera de produire trois à quatre publications scientifiques portant à la fois sur la vulnérabilité des architectures au-delà de ReLU (en particulier pour des activations telles que sigmoïde, tanh, GELU, SiLU/Swish) et sur les stratégies de protection adaptées.

2. Contexte du plan de la recherche

Les services de type « Machine Learning as a Service » (MLaaS) permettent d'interroger des modèles de Deep Learning à distance : un client envoie une entrée et reçoit en retour une prédiction. Ce modèle de déploiement est attractif pour l'industrie, mais il soulève plusieurs enjeux de sécurité.

D'un côté, les modèles déployés représentent un fort investissement en données d'apprentissage, en ressources de calcul et en savoir-faire. Les fournisseurs souhaitent donc éviter que ces modèles puissent être copiés ou reproduits par des concurrents ou des attaquants. De l'autre, les paramètres d'un modèle peuvent aussi révéler indirectement des informations sur les données d'entraînement, ce qui pose des questions de confidentialité.

Des travaux récents ont montré que, pour des réseaux de neurones à activation ReLU, il est possible d'extraire leurs paramètres en temps polynomial en interrogeant un oracle qui renvoie soit les sorties brutes du réseau (raw-output), soit uniquement le label final (hard-label). Ces attaques exploitent la structure géométrique particulière des réseaux ReLU, qui sont des fonctions affines par morceaux : l'espace d'entrée est découpé en régions linéaires par les hyperplans où les neurones changent d'état. La position des frontières de décision entre classes porte alors une information riche sur les poids internes.

Cependant, ces résultats concernent essentiellement des réseaux fully-connected à ReLU et se placent dans des modèles d'attaque encore relativement idéalisés. Dans la pratique, de nombreux modèles utilisent d'autres fonctions d'activation, des architectures convolutionnelles ou transformatives, et sont parfois protégés par des mécanismes de défense simples (limitation de requêtes, bruit, etc.). C'est dans cet écart entre les résultats théoriques existants et les systèmes réels que se situe le présent projet de thèse.

3. Problématique de recherche et objectifs

La question centrale de cette thèse peut se formuler de la manière suivante :

Dans quelle mesure est-il possible d'extraire des réseaux de neurones profonds modernes, au-delà des architectures ReLU classiques, en ne disposant que d'un oracle hard-label, et quels mécanismes de défense permettent de réduire efficacement cette vulnérabilité sans dégrader fortement la qualité des prédictions ?

Cette problématique se décline en deux volets complémentaires :

- un volet « vulnérabilité » : comprendre quelles familles de modèles (activations alternatives, architectures convolutionnelles, couches contractives, etc.) restent exposées à des attaques d'extraction efficaces ;
- un volet « protection » : concevoir et analyser des stratégies qui rendent ces attaques beaucoup plus difficiles ou coûteuses, tout en conservant une bonne performance prédictive.

Les objectifs scientifiques de la thèse sont les suivants :

- Formaliser un cadre d'analyse de l'extraction de modèles en mode hard-label pour différentes fonctions d'activation et architectures.
- Concevoir et étudier des attaques d'extraction généralisées, au-delà des réseaux ReLU fully-connected classiques.
- Proposer et analyser des mécanismes de défense (bruit, randomisation, limitations de requêtes, ensembles de modèles, etc.).
- Valider expérimentalement les attaques et défenses proposées sur des jeux de données de référence (MNIST, CIFAR-10, etc.).
- Valoriser les résultats sous forme de 3 à 4 publications scientifiques, combinant aspects théoriques et expérimentaux.

4. Pistes de recherche et méthodologie

La thèse s'articulera autour de deux grandes pistes de travail, liées mais distinctes.

Première piste : la généralisation des attaques d'extraction au-delà de ReLU. Il s'agira d'étudier la structure des frontières de décision pour d'autres fonctions d'activation (par exemple GELU, SiLU, tanh) et pour des architectures plus proches des systèmes réels (réseaux convolutionnels simples, architectures contractives). L'objectif est de comprendre dans quelle mesure les techniques existantes (points de transition, systèmes d'équations linéaires) peuvent être adaptées ou généralisées, et de proposer de nouvelles attaques lorsque c'est possible.

Deuxième piste : la conception de mécanismes de défense contre l'extraction. Une fois les vulnérabilités mieux comprises, l'enjeu est de proposer des moyens concrets de protéger les modèles exposés via des API. Par exemple, on pourra étudier l'impact de la limitation de requêtes, de l'ajout de bruit ou de la randomisation dans les réponses, ou encore de l'utilisation d'ensembles de modèles. Il faudra analyser précisément le compromis entre sécurité, performance et coût de mise en œuvre.

La méthodologie combinera analyse théorique (modélisation, preuves partielles), conception d'algorithmes d'attaque et de défense, et validation expérimentale à l'aide de Framework de Deep Learning modernes.

5. Résultats attendus et publications visées

Au terme de la thèse, plusieurs types de résultats sont attendus :

- des résultats théoriques sur la vulnérabilité à l'extraction de certaines architectures ou fonctions d'activation ;
- de nouveaux algorithmes d'attaque en mode hard-label pour des modèles au-delà de ReLU ;

- des propositions de mécanismes de défense accompagnées d’une analyse quantitative de leur efficacité et de leur impact ;
- des recommandations pratiques pour le déploiement plus sûr de modèles de Deep Learning via des API.

L’objectif est de valoriser ces résultats dans 3 à 4 articles scientifiques, par exemple :

- un premier article sur l’extension des attaques à des activations alternatives ;
- un ou deux articles comparant la vulnérabilité de différentes architectures profondes ;
- un article centré sur les défenses proposées et le compromis sécurité/performance.

6. Annexe : calendrier prévisionnel et publications

Le tableau ci-dessous présente un calendrier prévisionnel sur trois ans, avec les grandes étapes du projet et les publications visées. Il s’agit d’une base de travail qui pourra être ajustée en fonction de l’avancement et des opportunités scientifiques.

Période	Tâches principales	Résultats attendus	Publications visées
Année 1 – Semestre 1	Revue de littérature (extraction de modèles, activations, défenses). Reproduction d’une attaque existante sur réseaux ReLU.	État de l’art structuré. Première maîtrise pratique des attaques.	Possibilité d’un article de synthèse (survey court) ou d’un workshop.
Année 1 – Semestre 2	Analyse théorique ciblée sur les activations alternatives. Premiers prototypes d’attaque sur de petits modèles.	Premiers résultats sur la vulnérabilité de fonctions d’activation non ReLU.	Soumission d’un premier article sur les activations alternatives.
Année 2 – Semestre 1	Extension des attaques à des architectures	Mesures quantitatives de la qualité	Deuxième article sur la comparaison

	convolutionnelles simples. Expérimentations systématiques sur MNIST, CIFAR-10.	d'extraction et du coût en requêtes.	d'architectures (MLP vs CNN, etc.).
Année 2 – Semestre 2	Affinement des attaques, étude de scénarios d'attaque plus réalistes (contraintes de requêtes, bruit).	Meilleure compréhension des limites pratiques des attaques.	Article complémentaire ou extension des précédents résultats.
Année 3 – Semestre 1	Conception et implémentation de mécanismes de défense (bruit, randomisation, limitations de requêtes, ensembles de modèles).	Évaluation du compromis sécurité / performance pour différents scénarios.	Article principal centré sur les défenses et leur analyse.
Année 3 – Semestre 2	Consolidation des résultats, rédaction et finalisation du manuscrit. Préparation de la soutenance.	Manuscrit de thèse complet et synthèse des contributions.	Éventuelle soumission d'un dernier article de synthèse ou de journal.

7. Références

1. **Baum, E. B.** (1990). *A Polynomial Time Algorithm That Learns Two Hidden Unit Nets*. Neural Computation, **2**(4), 510–522.
2. **Baum, E. B.** (1991). *Neural net algorithms that learn in polynomial time from examples and queries*. IEEE Transactions on Neural Networks, **2**(1), 5–19
3. **Blum, A. L., & Rivest, R. L.** (1992). *Training a 3-node neural network is NP-complete*. Neural Networks, **5**(1), 117–127.

4. **Canales-Martínez, I. A., Chávez-Saab, J., Hambitzer, A., Rodríguez-Henríquez, F., Satpute, N., & Shamir, A.** *Polynomial Time Cryptanalytic Extraction of Neural Network Models*. Cryptology ePrint Archive, Paper 2023/1526.
5. **Canales-Martínez, I. A., Chávez-Saab, J., Hambitzer, A., Rodríguez-Henríquez, F., Satpute, N., & Shamir, A.** *Polynomial Time Cryptanalytic Extraction of Neural Network Models*. In M. Joye & G. Leander (Eds.), **Advances in Cryptology – EUROCRYPT 2024**, Lecture Notes in Computer Science, Vol. 14653, pp. 3–33. Springer Nature Switzerland.
6. **Carlini, N., Chávez-Saab, J., Hambitzer, A., Rodríguez-Henríquez, F., & Shamir, A.** *Polynomial Time Cryptanalytic Extraction of Deep Neural Networks in the Hard-Label Setting*. In S. Fehr & P. A. Fouque (Eds.), **Advances in Cryptology – EUROCRYPT 2025**, Lecture Notes in Computer Science, Vol. 15601, pp. 364–396. Springer Nature Switzerland.
7. **Carlini, N., Jagielski, M., & Mironov, I.** (2020). *Cryptanalytic Extraction of Neural Network Models*. In D. Micciancio & T. Ristenpart (Eds.), **Advances in Cryptology – CRYPTO 2020**, Lecture Notes in Computer Science, Vol. 12172, pp. 189–218. Springer.

Fait à Thiès, le 24 Décembre 2025

Le Directeur de thèse

Pr. Abdoul Aziz Ciss

École Polytechnique de Thiès

